

科研训练项目成果论文

浙 江 大 学

科研训练项目成果论文



题目 基于三维变焦重建与深度学习的

多材料表面缺陷检测技术

作者与学号 李申适 3230105050

指导教师 汪凯巍

年级与专业 2023级光电信息科学与工程

所在学院 光电科学与工程学院

完成日期 2026 年 5 月

摘要

表面缺陷检测不仅需要二维纹理信息，还需要能够反映凹坑、划痕、边缘突变和粗糙起伏的三维形貌信息。基于变焦焦栈的 Depth from Focus (DFF) 方法可在显微成像系统中利用不同焦平面的清晰度差异恢复相对高度，具有结构简单、可解释性强和易复现等优点。然而，多材料表面往往具有不同反射率、纹理密度、粗糙度和缺陷形貌，强反射、低纹理、周期纹理与多峰聚焦响应会导致传统 DFF 出现错误焦点和高度跳变。针对上述问题，本文围绕多材料表面缺陷形貌的相对三维重建与辅助可视化，建立了一条由真实焦栈验证和仿真真值评价共同组成的算法比较流程。

本文首先实现 Original DFF、后处理 DFF 和眩光感知 DFF (GADFF) 等传统可解释基线，并结合 Lee2013 自适应窗口和 Li2019 自适应迭代思想构建文献传统方法对比；随后利用程序生成表面构建包含柏林粗糙、分形粗糙、周期纹理、V 形谷、刃脊、阶跃和复合凹坑的仿真焦栈数据集；在此基础上训练 TinyDepthNet、Focus-ResUNet 与 Residual Focus-ResUNet 三类学习型校正模型。Focus-ResUNet 显式引入 17 层焦栈、16 层焦向差分以及 DFF/GADFF 先验通道，用以学习从聚焦响应体到相对高度图的非线性修正关系。

实验结果表明，在当前 7 个具有高度真值的仿真测试样本上，Focus-ResUNet 取得最低平均 MAE，为 $53.22\ \mu\text{m}$ ，优于 Original DFF 的 $100.55\ \mu\text{m}$ 、后处理 DFF 的 $63.81\ \mu\text{m}$ 、Lee2013 自适应窗口的 $62.35\ \mu\text{m}$ 和 TinyDepthNet 的 $57.31\ \mu\text{m}$ ，说明其在具有真值标定的样本上具有更强的监督学习能力和误差修正能力，但该结论限定于当前构建的仿真测试集。在真实样本相对三维重建中，TinyDepthNet 按本文采用的无真值保守可视化判据表现最稳健，其视觉稳定性和形貌自然性最好，说明轻量化模型路线中使用的判断基准更匹配当前实际样本的成像特征，不易把真实焦栈中的光照、噪声和局部反射差异过度解释为高度变化。综合来看，Focus-ResUNet 的优势主要体现在有真值约束的仿真定量评价中，TinyDepthNet 的优势主要体现在无真值真实样本的稳健可视化中；二者共同说明，当前项目已经形成了“真值样本学习能力验证”和“真实样本工程稳定性验证”两条互补证据链。由于真实样本缺少轮廓仪或标准台阶块真值，本文不宣称真实样本的绝对高度精度。

关键词：多材料表面；缺陷形貌表征；Depth from Focus；三维重建；Focus-ResUNet；深度学习

Abstract

Surface defect inspection requires not only two-dimensional texture cues but also three-dimensional morphology that reveals pits, scratches, edge discontinuities and rough height variations. Depth from Focus (DFF) reconstructs relative surface height from a focus stack by measuring the sharpness variation along the optical axis. It is attractive for microscopic inspection because of its simple hardware requirement, interpretability and reproducibility. Nevertheless, multi-material surfaces introduce diverse reflectance, texture density, roughness and defect geometries. Specular highlights, low-texture regions, periodic patterns and multi-peak focus responses may cause incorrect focus selection and unstable height jumps in traditional DFF methods. This work therefore studies focus-stack based relative 3D reconstruction and defect morphology visualization for multi-material surfaces, using real focus stacks for engineering validation and synthetic samples with ground truth for quantitative evaluation.

The proposed workflow first implements interpretable traditional baselines, including Original DFF, post-processed DFF and glare-aware DFF (GADFF). Lightweight baselines inspired by Lee2013 adaptive-window SFF and Li2019 adaptive-iteration SFF are also included. A synthetic focus-stack dataset is then generated with Perlin roughness, fractal roughness, periodic texture, V-shaped valleys, ridges, step structures and compound corrosion pits. Based on these data, three learning-based correction models are trained and compared: TinyDepthNet, Focus-ResUNet and Residual Focus-ResUNet. Focus-ResUNet explicitly uses a 17-frame focus stack, 16 differential-focus channels and DFF/GADFF prior maps to learn a nonlinear correction from focus responses to relative height maps.

Experiments on the current seven synthetic test samples with ground-truth height show that Focus-ResUNet achieves the lowest average MAE of $53.22\ \mu\text{m}$, outperforming Original DFF ($100.55\ \mu\text{m}$), post-processed DFF ($63.81\ \mu\text{m}$), Lee2013 adaptive window ($62.35\ \mu\text{m}$) and TinyDepthNet ($57.31\ \mu\text{m}$). This indicates that Focus-ResUNet has stronger supervised learning and error-correction capability when calibrated ground truth is available, while the conclusion is limited to the constructed synthetic test set. On real focus-stack samples without ground-truth height, TinyDepthNet provides the most stable and natural visual reconstruction under the conservative

no-ground-truth visualization criterion used in this work, suggesting that its lightweight correction criterion better matches the imaging characteristics of the current real samples and is less likely to over-interpret illumination, noise and local reflection variations as height changes. These two observations are complementary: Focus-ResUNet is more suitable for ground-truth constrained synthetic validation, whereas TinyDepthNet is currently more robust for real-sample visualization. Since no calibrated height reference is available for the real samples, this work does not claim absolute height accuracy on real data.

Keywords: multi-material surface; defect morphology characterization; Depth from Focus; 3D reconstruction; Focus-ResUNet; deep learning

目录

1	绪论	1
1.1	研究背景与意义	1
1.2	研究问题	2
1.3	研究内容与技术路线	2
1.4	本文贡献	3
2	相关工作	4
2.1	基于聚焦评价的三维形貌恢复	4
2.2	自适应窗口与迭代增强方法	4
2.3	深度学习与焦向差分特征	4
2.4	变焦显微三维测量与表面缺陷检测	5
3	样本数据与评价口径	6
3.1	真实焦栈样本	6
3.2	仿真焦栈样本	6
3.3	评价指标	8
4	方法	9
4.1	Original DFF 基线	9
4.2	后处理 DFF 与 GADFF	10
4.3	传统文献基线	10
4.4	TinyDepthNet	11
4.5	Focus-ResUNet	12
4.6	Residual Focus-ResUNet	14
5	实验结果与分析	15
5.1	仿真样本定量结果	15
5.2	P10 V 谷主案例分析	16
5.3	真实样本相对重建结果	19
5.4	结果讨论	22

6 结论与展望..... 23

 6.1 研究结论..... 23

 6.2 不足与后续工作..... 24

7 参考文献..... 25

附录..... 26

 A 主要数据与图件索引..... 26

 B 建议补充的局部放大图..... 26

 C 算法实现说明..... 26

 D 后续标定建议..... 27

1 绪论

1.1 研究背景与意义

材料表面的微小缺陷会直接影响零件的疲劳寿命、装配精度、接触可靠性和外观质量。在精密制造、增材制造、微孔加工、金属表面处理以及光电器件封装等场景中，缺陷并不总是表现为二维图像中的灰度异常，而往往体现为凹坑、划痕、毛刺、台阶、孔边缘塌陷和局部粗糙度变化等三维形貌差异。因此，单纯依赖二维强度图像进行表面检测，容易受到光照、反射和纹理方向的干扰，也难以判断缺陷的空间尺度和形貌类型。

三维表面测量方法包括接触式轮廓仪、共聚焦显微、白光干涉、结构光、双目视觉以及基于焦点变化的 Shape from Focus / Depth from Focus (SFF/DFF) 方法。其中，基于变焦焦栈的 DFF 方法通过采集同一视场在不同焦平面下的图像序列，计算每个像素在焦向上的聚焦评价响应，并将最清晰焦平面映射为相对高度。该方法不需要复杂扫描结构，能够利用普通显微成像系统进行相对三维恢复，具有可解释性强、实现成本低和便于工程复现等优点。

然而，多材料表面给 DFF 重建带来明显挑战。不同材料并不只是成分不同，更重要的是表面反射率、纹理密度、粗糙度和缺陷形貌不同：金属表面容易出现镜面反射和高亮饱和，3D 打印件常具有层纹和粗糙制造纹理，钥匙纹路和孔边缘具有方向性细密纹理和局部边缘突变，低纹理或强杂散光区域则可能产生不稳定的多峰聚焦响应。传统 DFF 在这些条件下容易把眩光或噪声误判为真实焦点，造成高度图中的孤立尖峰、边缘断裂和形貌扭曲。

本文面向“基于三维变焦重建与深度学习的多材料表面缺陷检测技术”这一项目任务，将研究重点收束为多材料表面焦栈的相对三维重建与缺陷形貌辅助表征。需要明确的是，本文所称“多材料表面”并非材料成分识别或材料类别分类，而是指算法面向多种表面成像特性和缺陷形貌进行验证；本文所称“缺陷检测”也不包含独立的缺陷分割、分类或报警模块，而是指通过相对高度图和三维形貌图为凹坑、划痕、台阶和孔边缘等缺陷形貌提供可视化依据。真实样本用于说明算法流程在实际焦栈上的可运行性与相对形貌表现；仿真样本具有高度真值，用于定量比较不同算法的高度误差。这一边界保证了结果解释的可靠性：本文不会把无真值真实样本写成绝对高度测量精度，而是在仿真数据上报告 MAE

等指标，在真实样本上报告相对三维重建与可视化稳定性。

1.2 研究问题

围绕多材料表面焦栈重建，本文主要关注以下问题：

1. 如何建立一条可复现的传统 DFF 基线，使真实焦栈能够被稳定转换为相对高度图。
2. 如何解释并缓解强反射、眩光、低纹理和多峰聚焦响应导致的错误焦点问题。
3. 如何构建具有高度真值的仿真样本，使不同算法能够在可控表面形貌和反射条件下进行定量比较。
4. 如何将焦栈原始图像、焦向差分信息以及 DFF/GADFF 先验融合到学习型模型中，提高复杂表面的高度恢复精度。
5. 如何正确区分仿真定量结论和真实样本无真值可视化结论，避免过度宣称。

1.3 研究内容与技术路线

本文的总体技术路线如图像处理和计算成像项目中常见的“传统基线-误差分析-仿真真值-学习校正-真实验证”链路所示。首先，以 Laplacian 和 Tenengrad 聚焦评价为基础实现 Original DFF，并通过中值滤波、高斯平滑和形态学处理形成 Original DFF + post 工程基线。其次，针对真实样本中观察到的高亮饱和和泛光现象，构建眩光风险图并形成 GADFF 方法，使强反射误差能够被显式建模。再次，引入 Lee2013 自适应窗口和 Li2019 自适应迭代思想，建立传统文献基线，避免只与最简单 DFF 方法比较。

在数据层面，本文同时使用真实样本和仿真样本。真实样本包括 3D 打印层纹、3D 打印表面、金属表面磕碰孔、钥匙纹路、圆孔、钥匙尖头和 1124 样本，主要用于验证流程的工程可运行性和相对形貌表现。仿真样本通过程序生成 V 谷、刃脊、山峰、山脊、阶跃、周期纹理和复合腐蚀凹坑，并加入柏林噪声、分形粗糙、条纹纹理和反射增强条件，从而提供可计算误差的高度真值。

在模型层面, 本文比较 TinyDepthNet、Focus-ResUNet 和 Residual Focus-ResUNet。TinyDepthNet 作为轻量学习型校正基线, 用于证明仿真监督可以修正传统 DFF 误差。Focus-ResUNet 借鉴 Differential Focus Volume 的焦向差分思想, 将 17 层焦栈、16 层相邻焦平面差分 and 5 个 DFF/GADFF 先验通道融合输入残差 U-Net, 是本文主要学习型模型。Residual Focus-ResUNet 则采用“先验深度 + 有界残差”的保守校正方式, 用于降低学习模型过度偏离传统先验的风险。

1.4 本文贡献

本文的主要工作和贡献如下:

1. 建立了面向多材料表面焦栈的相对三维重建流程, 覆盖 Original DFF、后处理 DFF、GADFF、Lee2013 自适应窗口、Li2019 自适应迭代和三类学习型模型。
2. 构建了用于算法定量验证的程序生成仿真样本集合, 使 MAE、高风险区误差和边缘区误差能够在有高度真值的条件下计算。
3. 将眩光风险、焦向差分和 DFF/GADFF 先验引入 Focus-ResUNet, 在当前 7 个仿真测试样本上取得最低平均 MAE, 并将该结论限定为当前有真值仿真测试集上的误差修正能力比较。
4. 对真实焦栈样本进行多算法相对三维重建展示, 并明确指出真实样本缺少标准高度真值, 因此其结果只用于工程可运行性、相对形貌和无真值稳定性验证。
5. 给出了仿真定量结果和真实视觉结果不完全一致的原因解释, 说明本文贡献主要是面向科研训练项目的算法比较框架和工程验证, 而不是完整缺陷检测系统或通用材料分类模型。

2 相关工作

2.1 基于聚焦评价的三维形貌恢复

SFF/DFE 方法的核心思想是：当物体表面某一点位于成像系统焦平面附近时，该点在图像中呈现更高的局部清晰度；当其离焦时，局部纹理和边缘会被模糊。因此，通过对焦栈中每一层图像计算聚焦评价值，并寻找响应最大的位置，可以估计该像素对应的相对高度。早期 **Shape from Focus** 研究已经证明，基于焦点变化的三维恢复能够从多焦平面图像中获得深度信息^[1]。后续研究进一步比较了多类聚焦评价算子，包括梯度、**Laplacian**、灰度方差和频域响应等^[2]。

聚焦评价算子的选择直接影响 DFE 的稳定性。梯度类算子对边缘和纹理敏感，能够较好地定位清晰区域；**Laplacian** 算子对高频细节和局部锐度敏感，但也容易放大噪声。实际系统中常将多种聚焦响应组合使用，以兼顾边缘定位和局部纹理响应。本文中的 **Original DFE** 采用 **Laplacian** 与 **Tenengrad** 梯度响应组合，作为可解释、可复现的传统基线。

2.2 自适应窗口与迭代增强方法

传统 DFE 需要在局部窗口内计算聚焦评价或进行响应平滑。窗口尺度过小会对噪声和纹理缺失敏感，窗口尺度过大则会平滑边缘、孔洞和细小缺陷。**Lee** 等提出的自适应窗口选择方法针对这一矛盾，根据局部结构特征调节窗口尺度，从而在低纹理区域提升稳定性，在边缘区域尽量保留结构^[3]。**Li** 等提出的自适应窗口迭代算法进一步通过迭代增强聚焦响应，改善复杂焦栈中的形貌恢复稳定性^[4]。

本文没有逐项复现上述论文的全部实验设置，而是将其核心思想实现为适配本项目 17 层焦栈的轻量传统基线。这样做的目的不是替代原论文结论，而是在同一数据、同一评价指标下提供比 **Original DFE** 更强的传统方法参照。

2.3 深度学习与焦向差分特征

深度学习方法能够从大量样本中学习非线性映射关系，在复杂纹理、噪声和反射条件下具有修正传统算法误差的潜力。对于 DFE 任务，模型不仅可以使使用单帧图像纹理，还

可以利用焦栈沿光轴方向的响应变化。Yang 等提出的 Differential Focus Volume 方法说明, 相邻焦平面之间的差分信息能够增强网络对焦点变化趋势的感知, 是深度 DFF 中重要的焦向上下文特征^[5]。

本文的 Focus-ResUNet 正是基于这一思想进行工程化改造: 模型输入不只包含原始 17 层焦栈, 还包含 16 层相邻焦平面差分, 以及由传统 DFF 和 GADFF 得到的先验深度、置信度和眩光风险通道。与完全端到端的黑箱估计相比, 这种设计保留了传统 DFF 的物理过程信息, 也让模型更容易学习“何处应该信任传统先验, 何处需要进行修正”。

2.4 变焦显微三维测量与表面缺陷检测

变焦显微三维测量在微结构检测、表面粗糙度分析和工业缺陷检测中具有较高应用价值。国内关于变焦显微三维测量系统和算法性能的研究指出, 焦栈成像过程中的聚焦评价、噪声抑制、步距设置和表面反射特性都会影响最终三维测量结果^[6-7]。这类研究为本文提供了系统背景: DFF 并不是单一算法问题, 而是成像系统、焦栈采集、聚焦评价和后处理共同决定的工程链路。

与绝对计量型三维测量不同, 本文当前真实样本没有轮廓仪、共聚焦显微或标准台阶块作为高度真值。因此, 本文将真实样本结果定位为相对三维重建和缺陷形貌可视化, 而将绝对误差评价限定在具有真值的仿真样本上。这种定位更符合当前数据条件, 也为后续补充真实标定数据留下清晰接口。

3 样本数据与评价口径

3.1 真实焦栈样本

本文使用的真实焦栈样本来自项目中期采集和整理的数据包，覆盖 3D 打印层纹、3D 打印表面、金属表面磕碰孔、钥匙纹路、圆孔、钥匙尖头和 1124 样本等类型。这些样本并不用于材料成分分类，而是用于覆盖不同表面成像条件：3D 打印样本代表层纹、粗糙制造表面和漫反射纹理；金属磕碰孔、钥匙纹路和钥匙尖头代表强反射、方向性细密纹理和局部边缘突变；圆孔和微孔类样本代表规则孔洞及孔边缘结构。

真实样本的主要价值在于检验算法流程能否在实际焦栈上运行，并观察相对高度图是否能够合理呈现表面形貌。由于这些样本没有同步采集轮廓仪、白光干涉、共聚焦显微或标准台阶块真值，本文不计算真实样本的绝对高度 MAE，也不宣称真实样本的绝对测量精度。真实样本只用于相对三维重建、聚焦置信度分析、动态范围观察和视觉稳定性比较。

表 3.1 给出了真实样本的成像特性归纳。表中“材料/表面属性”用于说明样本来源和表面状态，“主要成像挑战”用于说明其对 DFF 重建的意义。由于当前数据没有统一的材料牌号、粗糙度标定和相机参数记录，本文不把这些样本作为严格材料学分类数据集，而是作为多种真实表面成像条件下的工程验证样本。

3.2 仿真焦栈样本

为获得可定量评价的高度真值，本文构建了程序生成的仿真样本集合。仿真表面包括 P10 V 谷、A 型突起刃脊、山峰、山脊、阶跃、周期纹理和复合腐蚀凹坑等结构；表面纹理和扰动包含柏林噪声、分形粗糙、条纹周期纹理、凹坑划痕以及反射增强条件。仿真样本的目的不是完整替代真实材料的复杂光学过程，而是在可控条件下扩展粗糙度、纹理频率、反射风险和缺陷形貌，并提供高度真值用于误差计算。

本文最终用于算法对比的测试集包含 7 个代表性样本：P10 V 谷-宽谷粗糙平底、A 型刃脊-柏林粗糙、山峰-分形粗糙、山脊-柏林粗糙、阶跃-柏林粗糙、周期-条纹粗糙和复合腐蚀凹坑。每个样本都包含代表帧、焦栈、真值高度图、传统算法输出和学习型模型输出。

仿真数据采用训练集、验证集和测试集分离的方式组织。原始仿真集合包含 12 个训

表 3.1 真实焦栈样本的表面属性与成像挑战

样本类型	材料/表面属性	主要成像挑战	本文用途
3D 打印层纹	增材制造层状纹理	周期层纹、粗糙漫反射	验证层纹形貌连续性
3D 打印表面	粗糙制造表面	低纹理区与粗糙起伏并存	验证平滑与细节平衡
金属表面磕碰孔	金属反射表面与局部凹坑	镜面反射、孔边缘突变	验证强反射下的相对形貌
钥匙纹路	金属细密纹理	方向性纹理、局部高亮	验证细纹理稳定性
圆孔/微孔	规则孔洞边界	孔边缘陡变、内部低纹理	验证边界保持能力
钥匙尖头	金属尖锐边缘	尖端高亮、边缘遮挡与跳变	验证突变结构可视化
1124 样本	项目补充实物样本	形貌与反射条件混合	验证流程泛化运行

练样本、5 个验证样本和 7 个测试样本；在训练和验证阶段进一步加入反射增强样本后，学习型模型实际使用 27 个训练样本、10 个验证样本和 7 个固定测试样本。所有测试结论均来自未参与训练的 7 个代表性样本，因此本文将 Focus-ResUNet 的“最优”限定为当前测试集上的定量结论，而不外推为所有材料和所有相机条件下的普遍最优。

表 3.2 汇总了 7 个仿真测试样本的主要设置。仿真高度首先以归一化高度图表示，随后根据每个样本的 `depth_range_um` 转换为微米误差。因此，仿真 MAE 的单位为 μm ；真实样本因缺少标定高度范围，只报告归一化相对高度和无真值稳定性指标。

表 3.2 仿真测试样本设置

测试样本	结构与纹理类型	分辨率	高度范围 / μm
P10 V 谷-宽谷粗糙平底	宽谷、粗糙平底、反射风险	960×540	1200
A 型刃脊-柏林粗糙	突起刃脊、柏林粗糙	960×540	1280
山峰-分形粗糙	山峰结构、分形粗糙	640×360	1100
山脊-柏林粗糙	山脊结构、柏林粗糙	640×360	1020
阶跃-柏林粗糙	台阶结构、柏林粗糙	640×360	1040
周期-条纹粗糙	周期纹理、条纹粗糙	640×360	920
复合腐蚀凹坑	多尺度凹坑与沟槽	960×540	1420

3.3 评价指标

在仿真样本中，本文使用高度真值计算平均绝对误差（Mean Absolute Error, MAE）、高风险区 MAE 和边缘区 MAE。设真值高度为 H ，算法预测高度为 $\hat{H}$ ，像素集合为 Ω ，则 MAE 定义为：

$$\text{MAE} = \frac{1}{|\Omega|} \sum_{p \in \Omega} |\hat{H}(p) - H(p)|. \quad (3-1)$$

高风险区 MAE 在眩光风险图或异常反射风险较高的区域上计算，用于观察算法是否能处理强反射和杂散光影响；边缘区 MAE 在真值高度梯度较大的区域上计算，用于评价算法对孔边缘、阶跃和突起边界的保持能力。

真实样本中没有高度真值，因此采用无真值指标进行辅助观察，包括相对动态范围、粗糙度、边缘相关性、高风险跳变和低置信尖峰数量等。这些指标只能反映相对稳定性和视觉形貌特征，不能等价于真实高度误差。

其中，相对动态范围定义为相对高度图 95% 分位数与 5% 分位数的差，用于观察算法是否产生过窄或过宽的高度分布；粗糙度定义为相邻像素高度梯度的平均强度，用于衡量输出是否含有大量局部抖动；边缘相关性计算相对高度边缘与中间焦平面灰度边缘之间的相关趋势，用于辅助判断形貌边缘是否与图像结构一致；低置信尖峰数量统计低聚焦置信区域中的孤立高度突变，用于衡量真实样本中最容易影响三维可视化的伪峰问题。本文使用这些指标和人工视觉检查共同判断真实样本的稳健可视化效果，而不把它们解释为真实高度精度。

4 方法

4.1 Original DFF 基线

Original DFF 是本文的传统基础方法。给定包含 N 层图像的焦栈 $\{I_1, I_2, \dots, I_N\}$ ，对每一层图像计算聚焦评价响应 F_i 。本文使用 Laplacian 响应和 Tenengrad 梯度响应的组合，其中 Laplacian 强调局部二阶锐度变化，Tenengrad 使用 Sobel 梯度能量衡量边缘清晰程度。每个像素的最佳焦平面索引由最大聚焦响应确定：

$$k^*(p) = \arg \max_{i \in \{1, \dots, N\}} F_i(p). \quad (4-1)$$

随后将焦平面索引映射为归一化相对高度。由于项目焦栈方向约定为第一张图像对应较高焦平面，本文采用统一归一化映射：

$$D(p) = 1 - \frac{k^*(p) - 1}{N - 1}. \quad (4-2)$$

Original DFF 的优点是无需训练、可解释性强、能够直接用于真实焦栈；缺点是容易受到噪声、眩光、低纹理和多峰焦点干扰。

4.2 后处理 DFF 与 GADFF

Original DFF + post 在原始高度图上加入中值滤波、高斯平滑和形态学开运算，以抑制孤立尖峰和局部噪声。该方法不改变 DFF 的基本深度来源，主要提升真实样本的视觉稳定性，是项目中期阶段的工程化输出版本。

GADFF (Glare-Aware DFF) 针对真实样本中常见的高亮饱和、镜面反射和泛光区域构建眩光风险图。其基本思想是根据亮度异常、局部高亮面积和空间扩散特征判断风险区域，并在聚焦评价阶段对高风险区域进行降权。若 $R(p, i)$ 表示像素 p 在第 i 层的眩光风险，则可将原始聚焦响应修正为：

$$\tilde{F}_i(p) = F_i(p) \cdot (1 - \lambda R(p, i)), \quad (4-3)$$

其中 λ 为风险降权强度。GADFF 的主要作用是把“强反射导致错误焦点”转化为可计算的风险先验。实验表明，单独 GADFF 并不总能降低整体 MAE，但作为学习模型输入先验具有解释意义。

需要强调的是，GADFF 的负结果同样具有方法学意义。GADFF 在聚焦响应层面对高亮和杂散光区域降权，能够降低部分强反射伪焦点风险，但这种手工降权并不能区分“由眩光造成的高亮”和“真实结构边缘导致的高频响应”。在 P10 V 谷、刃脊和孔边缘等样本中，若风险图覆盖了真实结构边界，单独使用 GADFF 反而可能削弱有效聚焦响应，导致整体 MAE 升高。因此，本文不把 GADFF 作为最终独立最优算法，而将其定位为可解释的眩光风险先验：它更适合与学习型模型共同使用，由模型在监督误差约束下判断何处应采用风险降权、何处应保留原始焦向信息。

4.3 传统文献基线

Lee2013 adaptive window 方法根据局部纹理和结构复杂度选择不同窗口尺度。低纹理或平坦区域使用较大窗口以提升聚焦响应稳定性，边缘和细节区域使用较小窗口以减少结构平滑。本文将该思想实现为适配 17 层焦栈的轻量自适应窗口 DFF 基线。

Li2019 adaptive iteration 方法在自适应窗口基础上进一步进行聚焦响应迭代增强。该方法通过多轮平滑与响应强化减少孤立错误焦点，使焦点曲线更稳定。本文同样采用核心

思想复现，而不宣称完整复现原论文全部实现细节。

4.4 TinyDepthNet

TinyDepthNet 是本文第一版学习型校正基线。它不是直接复现某一篇深度 DFF 论文的完整网络，而是面向本项目仿真焦栈构建的小型卷积校正模型，用于验证“传统 DFF 输出能否被监督学习进一步修正”。其基本思想与 U-Net 类编码器-解码器网络中的局部卷积、非线性映射和端到端回归思想一致^[8]，但模型规模更小，不显式加入焦向差分体。

设原始焦栈为 $S = \{I_1, I_2, \dots, I_N\}$ ，其中 $N = 17$ 。TinyDepthNet 的输入由原始焦栈和 5 个先验通道拼接而成：

$$X_{\text{tiny}} = \text{concat}(I_1, \dots, I_N, R, D_{\text{DFF}}, C_{\text{DFF}}, D_{\text{GADFF}}, C_{\text{GADFF}}), \quad (4-4)$$

其中 R 为眩光风险图， D_{DFF} 与 C_{DFF} 分别为 Original DFF 深度和置信度， D_{GADFF} 与 C_{GADFF} 分别为 GADFF 深度和置信度。因此 $X_{\text{tiny}} \in \mathbb{R}^{(N+5) \times H \times W}$ 。模型输出为归一化相对高度图：

$$\hat{D}_{\text{tiny}} = \sigma(f_{\theta}(X_{\text{tiny}})), \quad (4-5)$$

其中 f_{θ} 表示卷积网络映射， $\sigma(\cdot)$ 用于将输出约束到 $[0, 1]$ 区间。训练时采用像素级 SmoothL1 损失与边缘一致性损失：

$$\mathcal{L}_{\text{tiny}} = \ell_{\text{smoothL1}}(\hat{D}, D) + 0.08 (\|\nabla_x \hat{D} - \nabla_x D\|_1 + \|\nabla_y \hat{D} - \nabla_y D\|_1), \quad (4-6)$$

其中 D 为仿真真值高度， ∇_x 和 ∇_y 表示水平与竖直方向的一阶差分。该损失使模型不仅拟合整体高度，还尽量保持主要边缘起伏。TinyDepthNet 的特点是输出较平滑、真实样本上视觉稳定性较好。虽然其模型容量有限，对复杂焦向上下文和结构边缘的建模能力不如 Focus-ResUNet，但这种轻量化路线也降低了模型对仿真分布的过拟合风险。在真实样本无高度真值的条件下，TinyDepthNet 所依赖的平滑性、局部一致性和传统 DFF 先验约束更接近当前实物焦栈的成像特征，因此其视觉结果更自然、更稳健。

4.5 Focus-ResUNet

Focus-ResUNet 是本文的主要学习型模型。该模型参考 U-Net 的多尺度编码-解码和跳跃连接结构^[8]，并引入 ResNet 中的残差块思想以提升深层特征传递稳定性^[9]。考虑到训练样本数量有限、batch size 较小，卷积块中采用 Group Normalization 代替依赖大 batch 统计量的归一化方式^[10]。与 TinyDepthNet 相比，Focus-ResUNet 的关键增量是显式加入焦向差分体，使模型能够学习相邻焦平面之间的清晰度变化趋势。

Focus-ResUNet 的输入融合三类信息：第一类是 17 层原始焦栈，用于保留真实灰度纹理和亮度信息；第二类是 16 层相邻焦平面差分，用于表达沿光轴方向的清晰度变化趋势；第三类是 DFF/GADFF 先验通道，包括眩光风险、DFF 深度、DFF 置信度、GADFF 深度和 GADFF 置信度。

焦向差分定义为：

$$\Delta I_i = I_{i+1} - I_i, \quad i = 1, 2, \dots, N-1. \quad (4-7)$$

记焦向差分体为 $\Delta S = \{\Delta I_1, \dots, \Delta I_{N-1}\}$ ，先验通道集合为 $P = \{R, D_{\text{DFF}}, C_{\text{DFF}}, D_{\text{GADFF}}, C_{\text{GADFF}}\}$ ，则模型输入可写为：

$$X_{\text{focus}} = \text{concat}(S, \Delta S, P), \quad (4-8)$$

其中 $X_{\text{focus}} \in \mathbb{R}^{(17+16+5) \times H \times W}$ 。模型首先分别对三组输入进行浅层卷积编码：

$$F_0 = \phi(\text{concat}(g_s(S), g_\Delta(\Delta S), g_p(P))), \quad (4-9)$$

其中 g_s 、 g_Δ 和 g_p 分别表示焦栈 stem、差分 stem 和先验 stem， $\phi(\cdot)$ 表示卷积、归一化与 SiLU 非线性激活的组合。随后网络进入残差 U-Net 主体。单个残差块可概括为：

$$\mathcal{B}(X) = \phi(\mathcal{N}(W_2 * \phi(\mathcal{N}(W_1 * X))) + W_s * X), \quad (4-10)$$

其中 W_1 和 W_2 为卷积核， W_s 为用于通道匹配的跳接卷积， $\mathcal{N}(\cdot)$ 表示 Group Normalization。编码器通过下采样获得多尺度特征，解码器通过上采样和跳跃连接恢复空间分辨率：

$$E_l = \mathcal{B}_l(\text{pool}(E_{l-1})), \quad D_l = \mathcal{B}'_l(\text{concat}(\text{up}(D_{l+1}), E_l)). \quad (4-11)$$

最终输出为：

$$\hat{D}_{\text{focus}} = \sigma(W_o * D_1 + b_o). \quad (4-12)$$

与只输入单层图像或只输入传统深度图相比，焦向差分使模型能够观察聚焦状态随焦平面移动的变化方向和变化幅度。训练损失包括深度误差、梯度一致性、曲率一致性、法向一致性和先验一致性，使模型既降低像素级高度误差，也尽量保持表面局部结构。具体而言，Focus-ResUNet 采用加权混合损失：

$$\mathcal{L}_{\text{focus}} = \mathcal{L}_{\text{data}} + 0.22\mathcal{L}_{\text{grad}} + 0.055\mathcal{L}_{\text{curv}} + 0.035\mathcal{L}_{\text{normal}} + 0.045\mathcal{L}_{\text{prior}}. \quad (4-13)$$

其中数据项采用眩光风险加权 Charbonnier 损失：

$$\mathcal{L}_{\text{data}} = \frac{1}{|\Omega|} \sum_{p \in \Omega} (1 + 0.80R(p)) \rho(\hat{D}(p) - D(p)), \quad \rho(x) = \sqrt{x^2 + \varepsilon^2}. \quad (4-14)$$

梯度项和曲率项分别约束一阶边缘与二阶形貌变化：

$$\mathcal{L}_{\text{grad}} = \rho(\nabla_x \hat{D} - \nabla_x D) + \rho(\nabla_y \hat{D} - \nabla_y D), \quad \mathcal{L}_{\text{curv}} = \rho(\nabla^2 \hat{D} - \nabla^2 D). \quad (4-15)$$

法向一致性项用局部高度梯度构造表面法向：

$$\mathbf{n}(\hat{D}) = \frac{[-\nabla_x \hat{D}, -\nabla_y \hat{D}, 1]}{\|[-\nabla_x \hat{D}, -\nabla_y \hat{D}, 1]\|_2}, \quad \mathcal{L}_{\text{normal}} = 1 - \mathbf{n}(\hat{D}) \cdot \mathbf{n}(D). \quad (4-16)$$

先验一致性项则在高置信、低眩光区域约束模型不要无依据地偏离传统 DFF/GADFF 深度：

$$\mathcal{L}_{\text{prior}} = \frac{\sum_p w_p \rho(\hat{D}(p) - D_p^0(p))}{\sum_p w_p + \varepsilon}, \quad D_p^0 = 0.45D_{\text{DFF}} + 0.55D_{\text{GADFF}}. \quad (4-17)$$

其中 $w_p = (0.65C_{\text{DFF}} + 0.35C_{\text{GADFF}})(1 - R)^{1.5}$ 。这种损失设计使 Focus-ResUNet 在眩光风险区域更重视真值监督和结构一致性，在传统聚焦评价高置信区域则保留 DFF/GADFF 先验的约束。

为保证算法比较具有可复现性，本文将主要学习型模型的训练设置汇总于表 4.1。所有学习型模型均在仿真样本上进行监督训练，输入 patch 尺寸为 128×128 ，推理阶段采用重叠分块方式恢复整幅高度图。TinyDepthNet 使用 17 层焦栈和 5 个 DFF/GADFF 先验通道；Focus-ResUNet 和 Residual Focus-ResUNet 进一步加入 16 层相邻焦平面差分，因此输入通道数为 38。本文主要关注算法路线和结论边界，未将硬件速度和模型参数量作为核心指标。

表 4.1 学习型模型训练与复现设置

项目	TinyDepthNet	Focus-ResUNet	Residual Focus-ResUNet
输入通道	17 层焦栈 + 5 个先验	17 层焦栈 + 16 层差分 + 5 个先验	同 Focus-ResUNet
训练/验证/测试	27 / 10 / 7 个仿真样本	27 / 10 / 7 个仿真样本	27 / 10 / 7 个仿真样本
patch 与 batch	128×128 , batch 8	128×128 , batch 6	128×128 , batch 6
每轮 patch 数	448 训练, 96 验证	384 训练, 96 验证	384 训练, 96 验证
训练轮数	10	12	10
优化器	AdamW, 7.5×10^{-4}	AdamW, 6.0×10^{-4}	AdamW, 5.0×10^{-4}
损失函数	SmoothL1 + 边缘损失	Charbonnier + 梯度/曲率/法向/先验一致性	混合损失 + 残差保护

4.6 Residual Focus-ResUNet

Residual Focus-ResUNet 是对 Focus-ResUNet 的保守改造。它不直接预测完整高度图，而是在 DFF/GADFF 先验深度基础上预测有界残差和门控系数。设先验深度为 D_0 ，模型预测残差为 ΔD ，门控系数为 G ，则最终输出为：

$$\hat{D} = D_0 + G \cdot \Delta D. \quad (4-18)$$

这种结构的目标是在传统先验可靠区域保持保守，在眩光、低纹理或复杂纹理区域进行有限修正。其优点是降低过度校正风险，缺点是在 P10 V 谷和周期纹理等传统 DFF 本身不可靠的困难样本上，修正幅度可能不足。

5 实验结果与分析

5.1 仿真样本定量结果

表 5.1 给出了 7 个仿真测试样本上的平均指标。可以看出，Original DFF 的平均 MAE 为 $100.55 \mu\text{m}$ ，说明直接基于最大聚焦响应选层在复杂表面上误差较大。Original DFF + post 将平均 MAE 降至 $63.81 \mu\text{m}$ ，表明空间后处理能够明显抑制噪声和孤立跳变。Lee2013 adaptive window 和 Li2019 adaptive iteration 的平均 MAE 分别为 $62.35 \mu\text{m}$ 和 $62.95 \mu\text{m}$ ，与后处理 DFF 接近，说明自适应窗口和迭代增强能提供合理的传统文献基线。

表 5.1 7 个仿真测试样本上的平均误差指标

方法	平均 MAE / μm	高风险区 MAE / μm	边缘区 MAE / μm
Original DFF	100.55	46.32	206.61
Original DFF + post	63.81	29.72	149.04
Lee2013 adaptive window	62.35	30.52	146.83
Li2019 adaptive iteration	62.95	31.24	145.33
GADFF	105.83	46.38	210.60
TinyDepthNet	57.31	42.63	89.10
Focus-ResUNet	53.22	40.14	86.68
Residual Focus-ResUNet	62.52	30.08	126.91

学习型模型总体优于传统 DFF。TinyDepthNet 的平均 MAE 为 $57.31 \mu\text{m}$ ，证明仿真监督能够学习到传统 DFF 误差的校正规律。Focus-ResUNet 取得最低平均 MAE $53.22 \mu\text{m}$ ，边缘区 MAE 也最低，为 $86.68 \mu\text{m}$ ，说明焦向差分 and 先验融合对复杂结构边界具有较好的修正效果。该结果可解释为：当样本具有明确高度真值时，Focus-ResUNet 能利用更丰富的焦向差分 and 先验通道进行监督学习，因此在模拟样本中表现出更强的误差拟合与校正能力。Residual Focus-ResUNet 平均 MAE 为 $62.52 \mu\text{m}$ ，与传统自适应方法接近，体现出保守残差保护在部分样本上会限制修正幅度。

需要注意，表 5.1 中 GADFF 的平均 MAE 为 $105.83 \mu\text{m}$ ，并未优于 Original DFF。这

说明手工眩光降权如果单独作为深度恢复规则，可能在真实边缘和强结构区域过度抑制有效聚焦响应。本文保留 GADFF 的原因并不是其作为独立算法取得最低误差，而是其提供了可解释的风险通道，使学习型模型能够在监督训练中选择性利用“强反射区域可能不可靠”这一先验信息。

图 5.1 以柱状图形式展示了各方法平均 MAE 的差异，图 5.2 和图 5.3 展示了代表性仿真样本的二维高度图和三维侧视对比。图中 GT 表示仿真真值高度，Post 表示 Original DFF + post, Lee13 和 Li19 分别表示本文参考 Lee2013 与 Li2019 思想实现的传统文献基线，Tiny、FRU 与 Res-FRU 分别表示 TinyDepthNet、Focus-ResUNet 与 Residual Focus-ResUNet。可以观察到，传统 DFF 在周期纹理、宽谷和强粗糙表面上容易出现局部跳变；后处理和自适应窗口能改善噪声，但可能平滑边缘；Focus-ResUNet 在整体形貌和边缘过渡上更接近真值。




图 5.1 不同算法在仿真测试集上的平均 MAE 对比

5.2 P10 V 谷主案例分析

P10 V 谷-宽谷粗糙平底样本是本文重点观察的困难案例。该样本具有较大深度范围、宽谷结构、粗糙平底和反射风险，传统 DFF 容易在谷底和边缘区域出现错误焦点。表 5.2 给出了该样本上的定量结果。

Original DFF 在 P10 上的 MAE 达到 $160.17 \mu\text{m}$ ，边缘区 MAE 达到 $270.77 \mu\text{m}$ ，说明宽谷边缘和粗糙平底对最大响应选层造成明显干扰。Li2019 adaptive iteration 将 MAE 降至 $98.08 \mu\text{m}$ ，并取得最低高风险区 MAE，说明传统迭代增强对该样本的风险区域具有一定稳




图 5.2 仿真样本多算法二维高度图对比




图 5.3 仿真样本多算法三维侧视对比

表 5.2 P10 V 谷主案例误差指标

方法	MAE / μm	高风险区 MAE / μm	边缘区 MAE / μm
Original DFF	160.17	39.23	270.77
Original DFF + post	120.87	29.31	227.46
Lee2013 adaptive window	102.60	32.77	192.92
Li2019 adaptive iteration	98.08	21.62	186.08
GADFF	167.46	39.23	282.00
TinyDepthNet	92.46	41.86	157.28
Focus-ResUNet	62.07	27.88	105.93
Residual Focus-ResUNet	101.57	26.15	178.44

定作用。Focus-ResUNet 的 MAE 进一步降低到 $62.07 \mu\text{m}$ ，边缘区 MAE 也降至 $105.93 \mu\text{m}$ ，是该主案例中的综合最优方法。该结果说明，焦向差分能够帮助模型识别焦点沿 Z 方向的变化趋势，DFF/GADFF 先验则为模型提供了可解释的初始深度和风险提示。

5.3 真实样本相对重建结果

真实样本结果如图 5.4 和图 5.5 所示。图 5.4 展示了磕碰孔、钥匙纹路、钥匙尖头和圆孔等样本的代表帧、相对高度图和聚焦置信度。图 5.5 汇总了多个算法在实物样本上的三维侧视结果。

从视觉效果和无真值稳定性指标看，TinyDepthNet 在真实样本上的输出整体更平滑，低置信尖峰数量较少，视觉上不容易出现大范围异常跳变，是当前真实样本相对重建中表现最稳的学习型模型。该结果说明，TinyDepthNet 这类轻量化路线采用的判断基准更贴近实际样本的成像特征：它更依赖局部一致性、传统 DFF 先验和保守平滑约束，而不是强行从有限真实焦栈中提取复杂焦向模式。Residual Focus-ResUNet 由于受到传统先验约束，部分样本上保持了更保守的相对形貌；Focus-ResUNet 在仿真中最优，但真实样本中受光照、噪声、反射和纹理分布差异影响，可能出现比 TinyDepthNet 更强的域差异敏感性。该现象并不与仿真结论矛盾，因为两类评价对象不同：仿真样本评价有真值高度误差，真实样本评价无真值条件下的相对形貌自然性和稳定性。




图 5.4 真实样本相对高度与聚焦置信度展示




图 5.5 真实样本多算法三维侧视总览

表 5.3 给出了真实样本上的无真值指标均值。可以看到，TinyDepthNet 的粗糙度最低，为 0.0067，低置信尖峰数量平均为 49，明显低于传统 DFF 类方法；Focus-ResUNet 的低置信尖峰数量更低，平均为 2，且边缘相关性最高，但其相对动态范围达到 0.5317，视觉上更容易放大真实样本中的局部反射和域外纹理差异。本文将真实样本判据设定为“保守、自然、少伪峰的缺陷形貌可视化”，因此综合视觉观察和无真值指标后，将 TinyDepthNet 视为当前真实样本上的最稳健方案，而不是宣称其具有最低真实高度误差。

表 5.3 真实样本无真值稳定性指标均值

方法	粗糙度	边缘相关性	相对动态范围	低置信尖峰数量
Original DFF	0.0977	-0.0394	0.6964	9179.7
Original DFF + post	0.0130	-0.0296	0.3944	4091.3
GADFF	0.0316	-0.0295	0.5406	3351.4
Lee2013 adaptive window	0.0295	-0.0209	0.6325	5018.7
Li2019 adaptive iteration	0.0318	-0.0233	0.6515	5433.6
TinyDepthNet	0.0067	-0.0243	0.3623	49.0
Focus-ResUNet	0.0078	0.0009	0.5317	2.0
Residual Focus-ResUNet	0.0594	-0.0343	0.5203	9262.1

因此，本文对真实样本的结论限定为：各算法均可在实际焦栈上生成相对三维形貌，TinyDepthNet 当前具有最稳定的真实样本视觉输出，说明轻量化模型判断基准与当前真实样本成像条件更匹配；Residual Focus-ResUNet 体现了保守先验保护的工程价值；Focus-ResUNet 则在仿真真值评价中展示了最强的误差修正能力。若要判断真实样本绝对高度精度，仍需引入轮廓仪、标准台阶块、白光干涉或共聚焦显微测量作为外部真值。

5.4 结果讨论

仿真结果和真实结果的排序差异是本文需要重点解释的现象。在仿真测试中，Focus-ResUNet 因输入信息最充分、模型表达能力较强，能够充分利用焦向差分和先验通道，因此获得最低平均 MAE。TinyDepthNet 虽然结构更小，但凭借学习型校正仍明显优于 Original

DFF。Residual Focus-ResUNet 在阶跃和复合凹坑等 DFF 先验相对可靠的样本上更保守，但在 P10 V 谷和周期纹理等困难样本上修正不足，导致平均指标未超过 Focus-ResUNet。

真实样本中，TinyDepthNet 的平滑倾向反而成为优势。真实焦栈存在仿真数据未完全覆盖的照明变化、传感器噪声、局部饱和、表面污染和机械步进误差，复杂模型更容易把这些域外特征解释为高度变化。TinyDepthNet 容量较小，输出较平滑，因此视觉稳定性较好；这说明其轻量化判断基准与实际样本的成像特征更匹配。Focus-ResUNet 在真实样本上的表现说明，仿真定量最优并不自动等价于真实无真值视觉最优。当前仿真样本属于轻量化模拟，主要用于控制表面形貌、粗糙度和相对反射风险，并未系统模拟不同相机设置和显微成像环境，例如景深变化、曝光差异、传感器噪声模型、强眩光、鬼像、杂散光路径和镜头像差等。因此，仿真数据能够支持有真值条件下的算法学习能力比较，但不足以完全代表真实材料和真实光学系统。后续应通过真实标定数据、域随机化、真实-仿真联合训练和结构类型门控来缩小域差异。

从物理量解释看，本文的高度输出首先是归一化相对高度 $D \in [0, 1]$ 。在仿真样本中，每个样本都保存了已知高度范围 $Z_{\max}$ ，因此预测误差可以通过 $|\hat{D} - D|Z_{\max}$ 转换为微米量级 MAE。真实样本只有焦栈层号和相对高度排序，缺少由标定台阶、物镜参数和实际步进量共同确定的高度映射，因此真实样本图中的高度颜色和三维表面仅表示相对形貌，不应解读为绝对微米高度。这个单位边界也是本文将 Focus-ResUNet 和 TinyDepthNet 分别放在“仿真定量最优”和“真实可视化最稳健”两个证据链中讨论的原因。

6 结论与展望

6.1 研究结论

本文围绕多材料表面缺陷形貌辅助表征中的相对三维重建问题，建立了从传统 DFF、眩光风险先验、文献传统基线到学习型深度校正模型的完整实验流程。研究表明，Original DFF 能够作为可解释、可复现的工程基线，但在强反射、低纹理、周期纹理和复杂边缘上容易出现错误焦点。后处理 DFF、自适应窗口和自适应迭代方法可以明显改善传统 DFF 的噪声和平滑矛盾，但仍受手工聚焦评价限制。

在具有高度真值的当前 7 个仿真测试样本上，Focus-ResUNet 取得最低平均 MAE

53.22 μm ，相较 Original DFF 的 100.55 μm 有明显下降；在 P10 V 谷主案例中，Focus-ResUNet 将 MAE 降至 62.07 μm ，说明焦向差分和 DFF/GADFF 先验融合能够有效提升复杂表面的误差修正能力，也说明该模型在有真值标定样本上具有更强的学习能力。真实样本实验表明，本文流程能够在多类实际焦栈上生成相对三维形貌，其中 TinyDepthNet 按保守可视化判据表现最稳健，说明轻量化路线下的判断基准更匹配实际样本成像特征。由于真实样本没有标准高度真值，相关结果只能作为相对重建和可视化验证，不能作为绝对测量精度结论。

6.2 不足与后续工作

本文仍存在三方面不足。第一，真实样本缺少轮廓仪、共聚焦显微或标准台阶块真值，无法进行真实高度误差评价。第二，仿真样本属于轻量化模拟，虽然覆盖了多种粗糙度、纹理和反射条件，但没有系统模拟不同相机设置和真实显微成像环境，例如景深、曝光、传感器噪声、强眩光、鬼像、杂散光路径和镜头像差等，因此仍不能完全代表真实材料的复杂光学成像过程。第三，学习型模型在仿真和真实之间存在域差异，仿真定量最优模型在真实样本视觉上不一定最稳。

后续工作应从以下方向展开：首先，采集带绝对高度标定的真实焦栈，建立真实样本 MAE、边缘误差和缺陷深度误差评价体系；其次，增加材料类型和缺陷类型，包括不同金属、聚合物、陶瓷、涂层和增材制造表面；再次，引入域随机化、风格迁移或无监督域适应，使仿真训练模型更好迁移到真实焦栈；最后，可根据表面结构类型设计门控策略，在 DFF 可靠区域保持传统先验，在眩光、低纹理和复杂纹理区域启用学习型校正，从而提高工程部署稳定性。若后续需要形成完整缺陷检测系统，还应在本文相对高度图基础上继续增加缺陷候选区域提取、形貌特征量化、阈值或学习型分类器，以及与人工标注缺陷区域对应的检测指标。

7 参考文献

- [1] NAYAR S K, NAKAGAWA Y. Shape from focus[J/OL]. IEEE Transactions on Pattern Analysis and Machine Intelligence, 1994, 16(8): 824-831. DOI: 10.1109/34.308479.
- [2] PERTUZ S, PUIG D, GARCIA M A. Analysis of focus measure operators for shape-from-focus[J/OL]. Pattern Recognition, 2013, 46(5): 1415-1432. DOI: 10.1016/j.patcog.2012.11.011.
- [3] LEE I, MAHMOOD M T, CHOI T S. Adaptive window selection for 3D shape recovery from image focus[J/OL]. Optics & Laser Technology, 2013, 45: 21-31. DOI: 10.1016/j.optlastec.2012.08.003.
- [4] LI L, PAN Z, CUI H, et al. Adaptive window iteration algorithm for enhancing 3D shape recovery from image focus[J/OL]. Chinese Optics Letters, 2019, 17(6): 061001. DOI: 10.3788/COL201917.061001.
- [5] YANG F, HUANG X, ZHOU Z. Deep Depth from Focus with Differential Focus Volume[C]//Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition. 2022: 12642-12651.
- [6] 尚明皓, 余飞鸿. 变焦显微三维测量系统的研究进展[J/OL]. 激光与光电子学进展, 2021, 58(16): 1600002. DOI: 10.3788/LOP202158.1600002.
- [7] 史艳琼, 尹秋霞, 卢荣胜. 变焦显微成像三维测量算法性能分析[J/OL]. 激光与光电子学进展, 2019, 56(7): 071202. DOI: 10.3788/LOP56.071202.
- [8] RONNEBERGER O, FISCHER P, BROX T. U-Net: Convolutional Networks for Biomedical Image Segmentation[C/OL]//Lecture Notes in Computer Science: Medical Image Computing and Computer-Assisted Intervention – MICCAI 2015: vol. 9351. Springer, 2015: 234-241. DOI: 10.1007/978-3-319-24574-4_28.
- [9] HE K, ZHANG X, REN S, et al. Deep Residual Learning for Image Recognition[C/OL]//Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition. 2016: 770-778. DOI: 10.1109/CVPR.2016.90.
- [10] WU Y, HE K. Group Normalization[C/OL]//Lecture Notes in Computer Science: Computer Vision – ECCV 2018: vol. 11217. Springer, 2018: 3-19. DOI: 10.1007/978-3-030-01261-8_1.

附录

A 主要数据与图件索引

本文使用的主要图件已整理至模板目录 `figure/project/`，其中包括仿真样本多算法二维高度图对比、仿真样本三维侧视对比、平均 MAE 对比图、真实样本相对高度与置信度展示图，以及真实样本多算法三维侧视总览图。原始项目材料位于项目根目录的 `02_Figures/`、`03_Data/`、`04_Code/` 和 `06_Samples/` 文件夹中。

B 建议补充的局部放大图

为进一步增强正文图像证据，后续重新绘图时建议补充两幅局部放大图。第一幅建议插入在图 5.2 与图 5.3 之后，建议命名为 P10 仿真 ROI 误差放大图。该图应以 P10 V 谷样本为对象，选取谷底到谷壁过渡的矩形 ROI，按“代表焦栈帧、真值高度、Original DFF、TinyDepthNet、Focus-ResUNet、Focus-ResUNet 绝对误差图”的顺序排布，并在每个算法子图上标注 ROI 内 MAE 与边缘区 MAE。图中应使用统一色标和同一空间坐标范围，重点展示 Focus-ResUNet 在谷壁边缘和粗糙平底处相对传统 DFF 的误差降低。

第二幅建议插入在图 5.5 与真实样本讨论段之间，建议命名为真实金属样本 ROI 稳定性放大图。该图应选择钥匙尖头、钥匙纹路或金属磕碰孔中的一个真实样本，选取包含强反射边缘和局部纹理的 ROI，按“代表焦栈帧、Original DFF、Original DFF + post、TinyDepthNet、Focus-ResUNet、低置信/尖峰掩膜”的顺序排布。由于真实样本无高度真值，该图不应绘制误差图，而应标注低置信尖峰数量、相对动态范围和局部粗糙度，重点说明 TinyDepthNet 输出更保守、更平滑，较少把反光和噪声解释为高度突变。

C 算法实现说明

本文中的 Lee2013 adaptive window 和 Li2019 adaptive iteration 均为根据文献核心思想实现的轻量版本，用于在同一焦栈和评价指标下提供传统算法基线。Focus-ResUNet 和 Residual Focus-ResUNet 为项目内基于仿真焦栈训练得到的学习型模型。由于真实样本没有标准高度真值，代码输出的真实样本指标仅用于相对稳定性分析，不用于绝对精度声明。

真实样本图中的高度色标均表示归一化相对高度，不应解释为绝对 μm 高度。

D 后续标定建议

若后续需要将本文方法推进到可计量的真实缺陷高度检测，应补充至少三类标定数据：第一，标准台阶块或标准微结构样本，用于确认焦栈层号到真实高度的映射关系；第二，轮廓仪、白光干涉或共聚焦显微测得的同视场高度图，用于计算真实 MAE 和边缘误差；第三，不同材料、不同反射条件和不同缺陷类型下的重复采样数据，用于评估模型跨材料和跨场景稳定性。